

Sistema de detección de caídas basado en sensores inercial y barométrico con algoritmos de Machine Learning

Glorioso Rego, Guido Ignacio

Departamento de Ingeniería Electrónica, Universidad Tecnológica Nacional FRBA, Buenos Aires, Argentina

guido.glorioso@frba.utn.edu.ar

RESUMEN

El progresivo envejecimiento demográfico demanda sistemas de teleasistencia eficaces para la detección automática de caídas. Si bien los dispositivos portátiles de muñeca favorecen la adopción por parte del usuario, presentan una alta tasa de falsas alarmas debido a los movimientos parásitos propios de las actividades de la vida diaria (ADL). Para mitigar esta problemática, el presente artículo propone una arquitectura híbrida de aprendizaje automático orientada a dispositivos de muñeca, fusionando datos inerciales y de altura. La metodología introducida se basa en un procesamiento segmentado: las señales de aceleración son evaluadas mediante Redes Neuronales Convolucionales (CNN) para la extracción automatizada de patrones espaciotemporales, mientras que los datos de presión atmosférica se procesan a través de la extracción de métricas estadísticas y algoritmos de clasificación supervisada para identificar variaciones netas de altitud. Se evaluaron estrategias de fusión de inferencias mediante enfoques secuenciales y de promedio ponderado. La validación empírica demuestra que la combinación de ambos modelos maximiza el rendimiento del sistema. Se consigue un resultado (F1-Score) global de 0.98, con una sensibilidad del 99% y una especificidad del 95%, superando las métricas del modelo de referencia.

Palabras clave: Detección de caídas, Dispositivos de muñeca, Machine Learning, Redes Neuronales Convolucionales, Fusión de sensores, Altimetros, Extracción de características.

ABSTRACT

The progressive aging of the population demands effective telecare systems for automatic fall detection. Although wrist-worn devices encourage user adoption, they exhibit a high rate of false alarms due to extraneous movements inherent to activities of daily living (ADL). To mitigate this issue, this paper proposes a hybrid machine learning architecture designed for wrist-worn devices, fusing inertial and altitude data. The proposed methodology relies on segmented processing: acceleration signals are evaluated using Convolutional Neural Networks (CNNs) for the automated extraction of spatiotemporal patterns, whereas atmospheric pressure data is processed through statistical feature extraction and supervised classification algorithms to identify net altitude variations. Inference fusion strategies were evaluated using both sequential and weighted average approaches. Empirical validation demonstrates that combining both models maximizes the system's performance. An overall F1-Score of 0.98 is achieved, with 99% sensitivity and 95% specificity, outperforming the metrics of the reference model.

Keywords: Fall detection, Wrist-worn devices, Machine learning, Convolutional Neural Networks, Sensor fusion, Altimeters, Feature extraction.

1. INTRODUCCIÓN

En la actualidad, la población de adultos mayores experimenta un incremento demográfico sostenido a nivel global, lo que viene acompañado de un aumento constante en los índices de caídas dentro de este rango etario.

Ante esta problemática, se han desarrollado múltiples trabajos orientados al diseño de sistemas capaces de detectar automáticamente estos eventos extremos, mitigando así sus consecuencias físicas y clínicas [1],

[2], [3].

Sin embargo, el desarrollo de estos dispositivos enfrenta desafíos críticos que limitan su adopción práctica. Entre ellos se destacan la calidad y representatividad de los conjuntos de datos, el costo computacional del procesamiento en tiempo real, el consumo energético de los nodos sensores, la cantidad y naturaleza de las variables físicas a registrar, y la necesidad de maximizar la precisión, especificidad y sensibilidad de las inferencias [1], [2].

A pesar de las ventajas operativas del monitoreo continuo, la literatura científica evidencia que la gran mayoría de los desarrollos tradicionales opta por fijar los dispositivos sensores en la cintura, el torso o el cuello [1], [2], [4]. Históricamente, se ha evitado el uso de dispositivos posicionados en la muñeca debido a que las extremidades superiores imponen una cantidad significativamente mayor de grados de libertad, introduciendo movimientos parásitos propios de la gesticulación diaria que generan una elevada complejidad en la determinación y modelado de los patrones de impacto reales [1].

Para mitigar las falsas alarmas provocadas por estos movimientos en entornos cotidianos, diversos autores han explorado la incorporación de sensores complementarios. En propuestas como las de Redmond et al. [4], se integra un transductor barométrico junto con el acelerómetro para añadir una referencia de altitud absoluta. Esta variable permite discernir de forma efectiva entre caídas reales y actividades de la vida diaria (ADL) que inducen señales cinemáticas similares —tales como sentarse abruptamente, acostarse con rapidez en la cama o golpear accidentalmente una superficie rígida—, basándose rigurosamente en la diferencia de altura neta registrada antes y después del impacto [2], [4].

Por otra parte, la interpretación computacional de las distintas señales se ha abordado desde diferentes vertientes algorítmicas. Por un lado, se destacan técnicas basadas estrictamente en el procesamiento digital de señales, como el detector de caídas propuesto por Pierleoni et al. [2]. En dicho esquema, las decisiones se toman a través de algoritmos deterministas de umbrales fijos nutridos por filtros complementarios y fusión de sensores en el propio dispositivo. Por otro lado, existen enfoques híbridos para dispositivos de muñeca que emplean metodologías masivas de extracción y selección de características (*feature selection + feature extraction*) en combinación de algoritmos tipo SVM [1]. Si bien este método destaca por alcanzar precisiones elevadas en entornos controlados, presenta la limitación operativa de requerir plataformas de alto cómputo o licencias de *software* propietario como MATLAB para la extracción de características, delegando el procesamiento pesado a servidores remotos para preservar la batería del dispositivo portátil [1]. Más recientemente, se han explorado arquitecturas basadas en Redes Neuronales Convolucionales (CNN) sobre el dataset masivo *FallAID* [3], donde la extracción de características en las señales de aceleración se realizan de manera automatizada mediante capas convolucionales profundas, derivando la inferencia final a una estructura de red neuronal densa.

A raíz de esto, en el trabajo correspondiente al dataset *FallAID* [3] se expone cómo la ausencia de bases de datos estandarizadas o la insuficiencia en la complejidad de los escenarios de prueba evaluados (como la frecuente omisión de caídas con recuperación inmediata o desvanecimientos lentos tipo síncope) dificulta la validación e interoperabilidad real de estos sistemas de teleasistencia.

A partir de estos antecedentes y limitaciones del estado del arte, el presente trabajo propone una mejora metodológica orientada a resolver la detección de caídas en dispositivos de muñeca mediante un enfoque híbrido de fusión de inferencias. La principal innovación radica en procesar las señales de los sensores de forma segmentada según su naturaleza: por un lado, se extrae un vector de características tabulares planas de baja complejidad computacional —compuesto principalmente por métricas estadísticas descriptivas— a partir de la señal del sensor barométrico; por otro lado, se emplean Redes Neuronales Convolucionales (CNN) para realizar la extracción automatizada de características a partir de las señales del acelerómetro. Este modelo toma como base el trabajo de [3], cuyo estudio evidenció que la inferencia en dispositivos de muñeca presentaba el desempeño más bajo.

2. DESARROLLO Y METODOLOGÍA

A continuación, se detalla el procedimiento metodológico junto con las técnicas adoptadas para el diseño e implementación del modelo completo. Tomando como punto de partida la arquitectura convolucional original propuesta en el estado del arte [3], se analizan y discuten las decisiones de diseño orientadas a optimizar la convergencia durante el entrenamiento y robustecer la generalización en la inferencia del modelo modificado. Asimismo, se estudia el comportamiento de este modelo y se justifica la incorporación de una arquitectura en paralelo que aprovecha las variables del sensor barométrico complementario. Finalmente, se evalúan las técnicas de fusión de decisiones implementadas para mitigar las falsas alarmas, identificando nuevas líneas de investigación y puntos de mejora para futuros desarrollos.

2.1. Conjunto y Aumento de Datos

La robustez y capacidad de generalización de los modelos implementados dependen críticamente de la distribución y el tratamiento de los conjuntos de datos. Con el propósito de evaluar el desempeño de

manera imparcial, el conjunto de datos cinemáticos de la muñeca se dividió estrictamente en tres particiones disjuntas: un 60% destinado al conjunto de entrenamiento (*train*), un 20% para el conjunto de validación (*validation*) durante la optimización de hiperparámetros, y el 20% restante reservado de forma aislada para el conjunto de testeo final (*test*).

Con el fin de expandir el volumen de la partición de entrenamiento y mitigar el sobreajuste provocado por la gesticulación de las extremidades superiores, se implementó una estrategia de aumento de datos (*data augmentation*) mediante la incorporación selectiva de registros provenientes de sensores ubicados en la cintura en el set de datos de entrenamiento. La distribución cuantitativa detallada de las muestras según la posición del sensor y el tipo de evento se condensa en el Cuadro 1.

La proporción de datos de cintura incorporados se dosificó según la naturaleza de cada señal.

Señales de Aceleración: Se integró un 30% de los registros de cintura para actuar como regularizador en la CNN. Esta dosificación controlada evita que el modelo se sobreajuste a la dinámica particular de la cintura, forzándolo a extraer patrones mas generales.

Señales de Presión Barométrica: Se incluyó el 100% de los datos de cintura. Esto se fundamenta en que las variaciones de presión atmosférica y diferencias de altura neta son similares en ambas posiciones corporales, expandiendo la representatividad estadística y optimizando la convergencia del modelo.

2.2. Modelo Inicial y Arquitectura de Referencia

En el trabajo de referencia propuesto por Saleh et al. [3], se introducen principalmente dos arquitecturas orientadas al procesamiento de señales cinemáticas, las cuales se diferencian estructuralmente por la tasa de muestreo de los sensores (configuradas a 40 Hz y 20 Hz respectivamente) y por la consecuente cantidad de parámetros requeridos para su ejecución. Para el desarrollo del presente artículo, se tomó como base el modelo de mayor envergadura, el cual se encuentra constituido por una primera etapa de extracción de características de tipo convolucional.

El entrenamiento de este bloque se realiza inicialmente bajo el paradigma de un autoencoder. Esta técnica de aprendizaje no supervisado fuerza a la red a comprimir la señal temporal de entrada en un espacio latente de baja dimensionalidad o vector de características (*features*), para luego decodificar dicha representación y reconstruir la señal original con la menor pérdida de información posible [5]. Una vez alcanzada la convergencia del autoencoder, se

desacopla la estructura del decodificador, preservando únicamente el codificador (*encoder*) como un extractor de características fijas. Sobre este espacio de características extraídas se conecta un bloque de clasificación denso (*head*) encargado de realizar la inferencia final del evento. La arquitectura original bajo este esquema presenta un total de 48 520 parámetros, obteniendo un resultado del 88% en especificidad (*precision*), 97% en sensibilidad y una puntuación *F1-Score* de 0.92, todos estos evaluados para un nivel de umbral de 30%, datos acordes a los expuestos en el trabajo original [3]. En la Figura 1 se encuentra ilustrada la arquitectura completa.




Figure 1. Diagrama de bloques de la arquitectura completa del modelo modificado para el procesamiento de acelerometría, incluyendo las capas de Batch Normalization y Dropout integradas.

Para reducir el sobreajuste, la red fue entrenada utilizando el conjunto de datos mixto (combinando registros de muñeca y cintura), tal como se detalló en la estrategia de aumento de datos.

Como resultado de esta combinación, el modelo alcanzó un desempeño del 92% para la sensibilidad y un 89% para la especificidad, dando como resultado una puntuación *F1-Score* de 0.91. Esta configuración habilita una generalización más robusta. Dicha capacidad de adaptación fue confirmada de manera empírica al validar la red directamente contra un conjunto de testeo compuesto en su totalidad por registros de cintura; en este escenario, el modelo obtuvo resultados de inferencia superiores al modelo entrenado con datos exclusivamente de muñeca.

Para evaluar el desempeño operativo del modelo en su entorno objetivo, se ejecutó una validación exhaustiva utilizando la totalidad del conjunto de datos de prueba correspondientes exclusivamente a la muñeca. Los resultados de esta evaluación y la distribución

Table 1. Distribución cuantitativa de las muestras según la localización del sensor y el tipo de evento registrado.

Posición del Sensor	Caídas	Eventos Cotidianos (ADL)	Total
Muñeca (Dataset Objetivo)	523	1992	2515
Cintura (Aumento de Datos)	466	1332	1798
Total Acumulado	989	3324	4313

de las inferencias se presentan gráficamente en la Figura 2. Es necesario remarcar que el modelo fue ajustado con gran parte de los datos presentes en la mencionada Figura, por lo que es esperable observar un rendimiento promedio superior.

3. INFERENCIA MEDIANTE PRESIÓN BAROMÉTRICA

Se aborda a continuación el acondicionamiento, procesamiento y transformación de las señales utilizadas para complementar el sistema de inferencia previo. Se utilizan como magnitud física de trabajo la altura del sujeto obtenida a partir de un sensor de presión concretamente el MS5607-02BA03.

3.1. Adquisición, Tratamiento de Datos y Extracción de Características

La justificación para integrar un segundo modelo fundamentado en variables barométricas radica en la necesidad de mitigar los falsos positivos generados por movimientos bruscos cotidianos que no conllevan un cambio real en la altitud del sujeto, como puede ser el movimiento de saludar con la mano. Este tipo de actividades diarias induce aceleraciones de gran magnitud que el modelo inercial previo podría clasificar erróneamente como un impacto por caída. El conjunto de datos está constituido por registros de presión atmosférica (medidos en hPa) y temperatura ambiente, adquiridos a una frecuencia de muestreo de 10 Hz. El transductor empleado opera bajo el principio de deformación mecánica de un diafragma sensible a la presión, realizando una medición diferencial mediante una referencia interna de una cavidad al vacío; como resultado se obtienen lecturas con valores estrictamente positivos [6]. Dado que la respuesta elástica de este tipo de sensores experimenta derivas debido a las fluctuaciones térmicas del entorno, se registra simultáneamente la temperatura ambiente para efectuar la correspondiente compensación y corrección del error térmico obteniendo la altura respecto al nivel del mar.

$$h = \frac{T_{\text{sensor}} + 273.15}{0.0065} \times \left[1 - \left(\frac{P_{\text{sensor}}}{P_o} \right)^{0.19} \right] \quad (1)$$

donde h representa la altura calculada, P es la presión atmosférica medida y P_0 denota la presión a nivel del mar (1013.25hpa). Con el propósito de disminuir el ruido de alta frecuencia intrínseco al sensado sin comprometer ni atenuar los datos reales, la señal de altura resultante se procesa mediante un filtro de mediana móvil con una ventana de 20 muestras.

Debido al carácter temporal de la señal, no es posible aplicarla directamente sobre arquitecturas de redes neuronales convencionales debido a la ausencia de relaciones temporales explícitas en sus capas de entrada estándar. En consecuencia, se implementa un método de extracción de características determinísticas. Siguiendo un criterio de simetría con el modelo del acelerómetro, se definen ventanas de análisis de 13 segundos, lo que equivale a un registro de 130 muestras conjuntas de presión y temperatura. A partir de este segmento temporal, se extraen 11 variables escalares, compuestas en su mayoría por estimadores estadísticos. En el trabajo propuesto por Bourke et al. [7] se optimiza este proceso mediante técnicas más complejas de extracción de características que permiten obtener valores más representativos del evento a clasificar a costa de un costo computacional mayor. Algunas de las métricas extraídas son **Valor RMS**, **Valor máximo absoluto**, **Ubicación temporal del mínimo**, **Asimetría estadística (*skewness*)**, **Desviación estándar STD**.

Como se ilustra en la Figura 3, el análisis y evaluación conjunta de este espacio multidimensional de métricas da lugar a agrupamientos (*clusters*) visualmente identificables, lo cual sugiere una separabilidad de los datos para la catalogación precisa de los eventos de interés.

3.2. Modelos de Inferencia

Existen múltiples métodos para detectar un cambio de altura, por ejemplo basado en la superación de un umbral crítico [2] o en algoritmos tradicionales de




Figure 2. Resultados del desempeño del modelo al ser evaluado sobre el conjunto de datos completo correspondiente a la muñeca.




Figure 3. Comparación del espacio de características extraídas de la señal barométrica. Se ilustra la formación de agrupamientos (*clusters*) basados en las métricas evaluadas, evidenciando la separabilidad entre eventos de caída y actividades cotidianas.

detección de flancos. No obstante, con el propósito de dotar al proceso de inferencia de una mayor capacidad de generalización y robustez ante las caídas, se propone y evalúa el uso de los siguientes paradigmas de aprendizaje automático supervisado **Redes Neuronales Artificiales (NN)**, **Árboles de Decisión**, **Máquinas de Soporte Vectorial (SVM)**.

3.2.1. Evaluación Comparativa


Para evaluar y comparar el desempeño de los modelos analizados, se recopilamos sus métricas de rendimiento en un escenario de validación específico. En la Tabla 2 se presentan los resultados obtenidos para los modelos indicados. En todos los casos se utilizó una salida de tipo sigmoide en donde el umbral de inferencia se evalúa entre 0.3 y 0.5 favoreciendo la especificidad del modelo.

3.2.2. Red Neuronal (NN)

El primer modelo implementado consiste en una arquitectura de red neuronal densa y secuencial de tipo *feedforward*. El vector de entrada es procesado inicialmente por una capa de normalización adaptada al conjunto de entrenamiento, garantizando la homogeneidad en las escalas de las distintas características. La estructura interna del modelo se compone de tres capas ocultas con funciones de activación ReLU y una capa de salida para la clasificación binaria, totalizando 351 parámetros. Se integraron capas de tipo (*Batch Normalization*) y capas de desconexión aleatoria (*Dropout*) con una tasa del 50% para reducir el overfitting. Asimismo, se aplicó una penalización de regularización L2 con un coeficiente de 0.01 en los pesos de cada capa densa. El proceso de optimización se llevó a cabo mediante el algoritmo ADAM, configurado con una tasa de aprendizaje (*learning rate*) constante de 1×10^{-4} . En la Figura 4 se detalla la estructura general.

Table 2. Comparativa de desempeño entre modelos de inferencia para mediciones de presión

Modelo	Sensibilidad	Especificidad	F1-Score	FP	FN
Red Neuronal (NN)	90%	86%	0.89	40/404	14/99
XGBClassifier	89%	96%	0.91	43/404	4/99
Support Vector Machine (SVM)	90%	80%	0.90	39/404	12/99


Figure 4. Arquitectura y flujo de capas de la red neuronal secuencial propuesta para el procesamiento de las características barométricas.

3.2.3. Algoritmo de Boosting de Árboles (XGBoost)

El segundo enfoque evaluado pertenece a la familia de métodos de aprendizaje supervisado basados en árboles de decisión, implementado mediante el clasificador XGBClassifier, que utiliza la técnica denominada **Extreme Gradient Boosting** (XGBoost). Este modelo fundamenta su inferencia en la construcción secuencial de múltiples árboles de decisión, donde cada nuevo árbol se entrena para corregir los errores residuales de los anteriores [8]. Para esta implementación, el algoritmo se configuró con un total de 40 árboles secuenciales, restringiendo la profundidad máxima de cada uno de ellos a 7 niveles. Otros hiperparámetros, como `scale_pos_weight` y `reg_lambda`, fueron optimizados mediante una búsqueda heurística de tipo *greedy search*, obteniéndose valores de 5 y 10, respectivamente.

3.3. Algoritmo SVM (Support Vector Machine)

Como tercer enfoque para la clasificación de eventos se implementó un modelo de Clasificación por Vectores de Soporte (SVM). Ante la no linealidad de las señales, se utilizó un kernel exponencial (RBF) definido según la ecuación 2:

$$K(x, x') = \exp(-\gamma \|x - x'\|^2) \quad (2)$$

Donde x y x' son vectores de características y $\|x - x'\|^2$ representa la distancia euclidiana al cuadrado. El comportamiento del modelo depende de dos hiperparámetros: C , que regula el compromiso entre el error de entrenamiento y la simplicidad de la frontera de decisión, y γ , que define de forma inversa el radio de influencia de los vectores de soporte. Mediante el método *greedy search* se optimizaron estos parámetros, obteniéndose los valores definitivos de $\gamma = 2.8$ y $C = 0.1$. Por último, para mitigar el desbalance de clases entre los eventos de caídas y las actividades de la vida diaria (ADS), se ajustó la función de pérdida asignando una relación de pesos de 4 : 1 a favor de la clase de caídas, priorizando así la sensibilidad del clasificador ante eventos críticos.

3.4. Fusión de modelos

Con el objetivo de incrementar el rendimiento predictivo y la robustez del sistema, se propone la integración del modelo base con los clasificadores descritos previamente, los cuales incorporan la información proveniente del sensor barométrico. Para llevar a cabo esta combinación, se plantean y analizan dos arquitecturas de ensamble distintas.

La primera metodología consiste en una configuración secuencial o en cascada. En este enfoque, un evento debe superar la evaluación de ambos modelos de manera sucesiva para ser catalogado como una caída. La premisa fundamental de este diseño radica en emplear inicialmente el clasificador que provea un mejor desempeño general como filtro primario; si este determina que la inferencia corresponde a una caída, el valor es filtrado y anulado para la siguiente etapa. Por el contrario, si el primer modelo detecta un ADS, la instancia avanza hacia el segundo modelo. La arquitectura detallada de este proceso se ilustra en la Figura 5. Cabe destacar que, bajo este esquema, el problema de optimización se centra en la sintonización de los umbrales de decisión independientes de ambos clasificadores.

El segundo método propuesto adopta un enfoque de fusión a nivel de decisión mediante un promedio ponderado. Las inferencias o probabilidades de salida de ambos clasificadores se combinan linealmente ponderando el porcentaje de peso otorgado a cada uno, dando lugar a un único valor consolidado. Este




Figure 5. Arquitectura del modelo secuencial para la detección de caídas.

puntaje es posteriormente evaluado frente a un umbral global del sistema para clasificar el evento. En este escenario, se cuenta con dos parámetros clave de optimización: los coeficientes de ponderación de cada modelo y el umbral de decisión final. La topología de esta combinación se expone en la Figura 6.




Figure 6. Esquema de fusión de modelos mediante promedio ponderado.

Para ambas arquitecturas, la calibración y optimización de los parámetros se llevó a cabo utilizando el análisis de las curvas ROC junto con el estudio de las distribuciones de probabilidad del modelo. Estas últimas constituyen una herramienta analítica fundamental, dado que permiten visualizar gráficamente cómo la selección de cada umbral afecta directamente a las inferencias resultantes, facilitando la obtención de un valor optimizado según las necesidades específicas y la tolerancia al riesgo del sistema. En la Tabla 3 se observan los resultados obtenidos para cada una de las combinaciones posibles de los modelos y su método de combinación.

4. RESULTADOS

Se presentan los resultados obtenidos tras la evaluación empírica de las distintas arquitecturas de fusión propuestas. El análisis de desempeño detallado para cada combinación, incluyendo los parámetros de ajuste óptimos y las métricas de clasificación, se encuentra resumido en la Tabla 3.

Al analizar el desempeño general de los clasificadores, se destaca la superioridad del modelo basado en *XGBClassifier* fusionado con la red CNN. Esta combinación logró las métricas más altas de la prueba, alcanzando un F1-Score de 0.97 en ambas arquitecturas y destacándose por su alta sensibilidad (98% en el enfoque secuencial y 99% en el

ponderado), logrando reducir al mínimo la cantidad de falsos positivos frente al total de muestras. En segundo lugar en orden de eficacia, el ensamble compuesto por la Red Neuronal y la CNN demostró un comportamiento sumamente equilibrado, obteniendo especificidades del 95% y 97% según el método empleado, superando ampliamente al modelo basado en SVM, el cual presentó la mayor degradación en el rechazo de falsas alarmas.


Un aspecto crítico en los resultados obtenidos es la estrategia adoptada para la selección de los hiperparámetros. En el caso de la combinación secuencial, la lógica de sintonización consistió en establecer un primer filtrado (correspondiente al modelo del acelerómetro) con un umbral de exigencia bajo ($H1 = 0.1$ para las redes neuronales y árboles). El propósito de esta configuración fue garantizar que el modelo primario no catalogue erróneamente eventos críticos como si fuesen de la vida diaria, actuando como un filtro de alta permisividad para las caídas. En consecuencia, la responsabilidad de realizar la discriminación fina recayó sobre el segundo modelo (basado en el barómetro), el cual operó con un umbral más estricto ($H2$) encargado de descartar definitivamente las actividades estacionarias (ADS). Finalmente, al contrastar las metodologías de fusión, el método de promedio ponderado evidenció un rendimiento global superior frente al enfoque secuencial. Las ventajas de esta arquitectura no solo se vieron reflejadas en la mejora cualitativa de las métricas duras (como la reducción de falsos negativos en la Red Neuronal y SVM), sino fundamentalmente en la morfología de las respuestas del modelo. El análisis de la distribución de probabilidades 7 arrojó que la fusión ponderada logra distanciar con mayor eficacia los clústeres representativos de las caídas respecto a los de las secuencias ADS. Esta mayor separación espacial entre las distribuciones de ambas clases le otorga al sistema una robustez significativamente mayor ante la presencia de ruido, permitiendo establecer un umbral de decisión final con un mayor margen de seguridad e incrementando la confiabilidad global de las inferencias.

La Figura 8 expone los resultados detallados del modelo con mejor desempeño (*XGBClassifier* fusionado mediante promedio ponderado) al ser evaluado sobre la totalidad del conjunto de datos. Las métricas de evaluación sobre este escenario arrojaron un rendimiento excepcional, con una sensibilidad del 99% y una especificidad del 95%, culminando en un F1-Score global de 0.98.

Al realizar un análisis exhaustivo de las clasificaciones erróneas, se identificaron los escenarios que introducen mayor complejidad algorítmica para el

Table 3. Comparativa de desempeño entre modelos combinados

Modelo Barómetro	Modelo Acelerómetro	Tipo de Combinación	H1 K	H2	Sens.	Espec.	F1 Score	FP	FN
Red Neuronal	CNN	Secuencial	0.1	0.2	93%	95%	0.94	27/404	5/99
XGBClassifier	CNN	Secuencial	0.1	0.4	98%	94%	0.97	10/404	6/99
SVM	CNN	Secuencial	0.2	0.5	98%	84%	0.95	8/404	16/99
Red Neuronal	CNN	Ponderado	0.5	0.3	95%	97%	0.96	19/404	3/99
XGBClassifier	CNN	Ponderado	0.5	0.5	99%	92%	0.97	6/404	8/99
SVM	CNN	Ponderado	0.3	0.35	97%	87%	0.95	12/404	13/99


Figure 7. Curva ROC (Receiver Operating Characteristic) del modelo implementado con XGBClassifier con combinación ponderada y distribución de probabilidades

sistema. Dentro del grupo de los falsos negativos (eventos de riesgo no detectados), la mayor dificultad se presentó en las caídas desde la cama, registrando 10 eventos mal catalogados sobre un total de 25 ocurrencias. El segundo grupo con mayor tasa de omisión correspondió a las caídas por deslizamiento durante la marcha, sumando un total de 6 incidentes. Por parte de los falsos positivos, se observó que la principal fuente de confusión del sistema, causante de activaciones espurias, proviene de los movimientos abruptos de las manos o extremidades superiores, los cuales generaron 14 falsas alarmas. A estos les siguieron las acciones asociadas a sentarse de manera repentina, aportando un total de 4 ocurrencias erróneas que el modelo interpretó como caídas.

5. DISCUSIÓN Y TRABAJOS FUTUROS

A partir del análisis de los resultados obtenidos, se han identificado diversas líneas de investigación

y optimización para futuras iteraciones del sistema. Como primera instancia, resulta imperativo disminuir la tasa de omisión (falsos negativos) ante dinámicas cinemáticas complejas, particularmente en las caídas por deslizamiento o aquellas originadas desde la cama. Estos escenarios representan un desafío algorítmico donde el modelo actual requiere mejorar su capacidad de generalización. Para abordar esta limitación, se propone explorar métodos de extracción de características (*features*) más robustos. La incorporación de metodologías consolidadas en el estado del arte, como el enfoque propuesto por Bourke et al. [7], podría incrementar significativamente la calidad predictiva de las inferencias, en especial para los clasificadores basados en el sensor barométrico. Por otro lado, un hallazgo crítico derivado de la evaluación empírica fue la alta sensibilidad del desempeño del sistema frente a la orientación física del dispositivo. Se comprobó que las variaciones en la disposición del equipo pueden degradar drásticamente las métricas, llegando a reducir la especificidad en un 78%. Para dotar al sistema de invariancia espacial, los trabajos futuros deberán contemplar el desarrollo de un algoritmo de compensación que efectúe una rotación matemática continua de los ejes del sensor, tomando como referencia absoluta la estimación direccional del vector de gravedad.

Desde el punto de vista del costo computacional y la eficiencia embebida, existe margen para simplificar la cadena de preprocesamiento de las señales. Etapas actuales, como la aplicación de filtros de mediana sobre la señal de presión y su posterior transformación a valores de altitud relativa, consumen recursos que podrían optimizarse. Una alternativa viable radicaría en la aplicación de algoritmos de corrección y compensación de temperatura de manera directa sobre los datos del sensor, permitiendo prescindir de estas etapas intermedias y agilizando la cadena de adquisición.

Finalmente, en lo que respecta a la arquitectura de clasificación, se proyecta la evolución del sistema hacia un esquema de fusión de datos a nivel temprano (*early fusion*). El objetivo consistirá en




Figure 8. Resultados de inferencia global sobre el dataset completo utilizando XGBClassifier con fusión ponderada.

migrar de las topologías de combinación expuestas (secuenciales y ponderadas) hacia el entrenamiento de un único modelo global. En este marco unificado, las características extraídas tanto del acelerómetro como del barómetro coexistirán matricialmente desde el inicio. Esta integración no solo eliminaría la necesidad de mantener etapas de inferencia separadas, simplificando la topología general, sino que también podría permitir al algoritmo capturar correlaciones cruzadas entre ambas magnitudes físicas.

6. CONCLUSIONES

En el presente trabajo se demostró que la integración de datos cinemáticos provenientes de diversas ubicaciones anatómicas, tales como la cintura y las muñecas, puede coexistir de manera efectiva dentro del conjunto de entrenamiento, fortaleciendo la capacidad de generalización del modelo frente a diferentes escenarios de caídas.

Asimismo, se lograron superar las métricas de desempeño reportadas en el estudio de Saleh et al. [3]. Mientras que dicho trabajo de referencia alcanzó una sensibilidad del 87% y una especificidad del 94.53%, la arquitectura aquí propuesta elevó estos indicadores a 95.22% y 98.74%, respectivamente. Resulta destacable que esta mejora se obtuvo operando con una baja frecuencia de adquisición (10 Hz) y prescindiendo de la implementación de algoritmos de fusión sensorial de alta complejidad algorítmica.

Por otro lado, la evaluación empírica comprobó que la incorporación de la información proveniente del sensor barométrico constituye un factor clave, aportando una validación secundaria que mejora y robustece los resultados del clasificador principal.

Si bien existen arquitecturas en el estado del arte capaces de superar las métricas absolutas aquí expuestas —usualmente a expensas de un marcado incremento en el costo computacional o en la cantidad de parámetros del modelo—, la metodología desarrollada se posiciona como un punto de partida sólido y viable para la creación de sistemas eficientes. Este estudio valida la conveniencia de explotar la inferencia complementaria entre los datos de acelerometría y presión atmosférica, priorizando un equilibrio óptimo entre la precisión diagnóstica y la factibilidad técnica para su eventual implementación en sistemas embebidos de bajos recursos.

7. REFERENCIAS

- [1] M. Saleh, N. Georgi, M. Abbas, and R. Le Bouquin Jeannès, “A highly reliable wrist-worn acceleration-based fall detector,” in *Proceedings of the 27th European Signal Processing Conference (EUSIPCO)*, IEEE, 2019, pp. 1658–1662.
- [2] P. Pierleoni et al., “A wearable fall detector for elderly people based on ahrs and barometric sensor,” *IEEE Sensors Journal*, vol. 16, no. 17, pp. 6733–6744, 2016.
- [3] M. Saleh, M. Abbas, and R. Le Bouquin Jeannès, “Fallalld: An open dataset of human falls and activities of daily living for classical and deep learning applications,” *IEEE Sensors Journal*, vol. 20, 2020, Accepted for publication, DOI: 10.1109/JSEN.2020.3018335.
- [4] S. J. Redmond, N. H. Lovell, T. Jämsä Jämsä, and others, “Prior-to- and post-impact fall detection using inertial and barometric altimeter measurements,” *IEEE Transactions on Biomedical Engineering*, vol. 59, no. 11, pp. 3012–3020, 2012.

- [5] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016, [http : / / www . deeplearningbook.org](http://www.deeplearningbook.org).
- [6] J. Fraden, *Handbook of Modern Sensors: Physics, Designs, and Applications*. Springer Science & Business Media, 2010.
- [7] A. K. Bourke, J. V. O'Brien, and G. M. Lyons, "A highly reliable wrist-worn acceleration-based fall detector," *Biomedical Engineering Online*, vol. 6, no. 1, pp. 1–16, 2007.
- [8] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001. DOI: 10.1214/aos/1013203451.